Chapitre 6 — Statistique à deux variables

Nuage de points, ajustement affine, changement de variable, corrélation et causalité

Cours · Méthodes · Exercices par niveau · Corrections · Exercice bilan

Terminale — Mathématiques complémentaires

CE QUE TU DOIS SAVOIR FAIRE À LA FIN DE CETTE FICHE

- ☐ Je sais représenter un nuage de points.
- ☐ Je sais calculer et placer le point moyen.
- ☐ Je sais obtenir la droite d'ajustement à la calculatrice.
- ☐ Je sais interpréter le coefficient de corrélation.
- ☐ Je sais faire une prévision et en discuter la validité.
- ☐ Je sais linéariser un modèle exponentiel.
- ☐ Je distingue corrélation et causalité.

AVANT DE COMMENCER — CE QU'IL FAUT DÉJÀ SAVOIR

Prérequis : moyenne, fonction affine, logarithme (chapitre 3), exponentielle (chapitre 4).

Ce chapitre s'utilise beaucoup avec la calculatrice : il faut savoir où se trouvent les menus `STAT` et `RÉGRESSION`.

1. Le cours

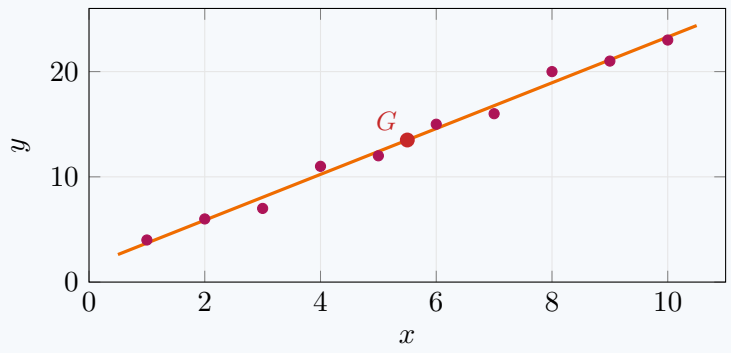
COURS — Nuage de points et point moyen

On étudie deux caractères sur une même population : on obtient une série de couples $(x_i\,;y_i)$.

Le **nuage de points** est l'ensemble des points de coordonnées $(x_i\,;y_i)$.

Le **point moyen** G a pour coordonnées

$$G(\bar{x}\,;\bar{y}) \qquad \text{avec} \qquad \bar{x}=\frac{1}{n}\sum x_i, \quad \bar{y}=\frac{1}{n}\sum y_i.$$



La droite d'ajustement par les moindres carrés passe **toujours** par le point moyen G.

COURS — Ajustement affine et corrélation

La **droite des moindres carrés** de y en x est la droite $y = ax + b$ qui rend minimale la somme des carrés des écarts verticaux entre les points et la droite.

On l'obtient **à la calculatrice** : menu statistiques, régression linéaire.

Le **coefficient de corrélation linéaire** r mesure la qualité de l'ajustement :

Valeur de r	Interprétation
$r = 1$	points parfaitement alignés, pente positive
$r = -1$	points parfaitement alignés, pente négative
$\lvert r\rvert > 0{,}95$	ajustement affine très satisfaisant
$0{,}8 < \lvert r\rvert < 0{,}95$	ajustement acceptable, à discuter
$\lvert r\rvert$ proche de 0	aucune relation affine

r a toujours *le même signe que* a.

⚠ Un r proche de 0 ne signifie pas « aucun lien » : il signifie « aucun lien *affine* ». Deux variables peuvent être parfaitement liées par une parabole avec $r \approx 0$.

COURS — Interpolation et extrapolation

Interpolation	Extrapolation
On prédit à l'*intérieur* de la plage des données observées	On prédit *au-delà* de cette plage
Généralement fiable	À manier avec prudence

Pourquoi ? Rien ne garantit que la tendance observée se poursuive. Un modèle affine de croissance d'un enfant prédirait une taille de 4 m à 40 ans : la relation n'est valable que sur la plage étudiée.

Rédaction attendue. « D'après ce modèle, on peut estimer… Cette estimation reste une extrapolation : elle suppose que la tendance observée se poursuit. »

COURS — Ajustement par changement de variable

Quand le nuage n'est manifestement pas aligné, on *linéarise* le modèle.

Modèle	On pose	Alors
$y = A\,e^{bx}$ (exponentiel)	$z = \ln y$	$z = bx + \ln A$: affine en x
$y = A\,x^{b}$ (puissance)	$z = \ln y$, $t = \ln x$	$z = bt + \ln A$: affine en t
$y = \dfrac{A}{x}$	$t = \dfrac{1}{x}$	$y = At$: linéaire en t

Méthode. On calcule les $z_i = \ln y_i$, on ajuste z par une droite $z = \alpha x + \beta$, puis on revient au modèle :

$$y = e^{z} = e^{\alpha x + \beta} = e^{\beta} \times e^{\alpha x}.$$

Donc $A = e^{\beta}$ et $b = \alpha$.

COURS — Corrélation n'est pas causalité

Deux variables peuvent être fortement corrélées sans qu'aucune ne cause l'autre.

Explication possible	Exemple
Causalité réelle	La quantité d'engrais influe sur le rendement.
Facteur commun (variable cachée)	Ventes de glaces et noyades augmentent ensemble : c'est la chaleur qui explique les deux.
Causalité inversée	On observe plus de pompiers là où les incendies sont graves : ce ne sont pas les pompiers qui causent les incendies.
Coïncidence	Sur 20 ans, deux séries sans rapport peuvent être corrélées par hasard.

Une corrélation **signale** une relation à expliquer. Elle ne la **démontre** pas.

★ À RETENIR PAR CŒUR

— La droite de régression passe par $G(\bar{x}\,;\bar{y})$.

— $r \in [-1\,;1]$, et $|r|$ proche de 1 signifie « bien aligné ».

— r mesure une relation *affine*, rien d'autre.

— Extrapoler, c'est faire une hypothèse supplémentaire : le dire explicitement.

— Modèle exponentiel : poser $z = \ln y$.

— Corrélation $\neq$ causalité.

2. Les méthodes

MÉTHODE — Ajuster et prévoir — la marche à suivre

Étape 1 — Saisir les données dans la calculatrice
Liste L_1 pour les x, liste L_2 pour les y.

Étape 2 — Lire l'équation et le coefficient r
Menu régression linéaire. Arrondir les coefficients comme demandé — pas plus.

Étape 3 — Justifier la pertinence de l'ajustement
Une phrase avec la valeur de r.

Étape 4 — Faire la prévision et la commenter

Exemple de rédaction.
« À la calculatrice, on obtient $y = 2{,}18x + 1{,}53$ avec $r \approx 0{,}997$.
Comme $|r|$ est très proche de 1, l'ajustement affine est justifié.
Pour $x = 14$: $y \approx 2{,}18 \times 14 + 1{,}53 \approx 32$.
Il s'agit d'une extrapolation : elle n'est valable que si la tendance se poursuit. »

MÉTHODE — Linéariser un modèle exponentiel

Étape 1 — Calculer les $z_i = \ln y_i$
Une ligne de tableau supplémentaire, arrondie à 10^{-3}.

Étape 2 — Ajuster z en fonction de x
On obtient $z = \alpha x + \beta$.

Étape 3 — Revenir à y
$y = e^{\alpha x+\beta} = e^{\beta} \times (e^{\alpha})^{x}$.

Étape 4 — Interpréter
e^{α} est le coefficient multiplicateur par unité de x.

Exemple. Si $z = 0{,}12x + 4{,}6$, alors

$$y = e^{4{,}6} \times e^{0{,}12x} \approx 99{,}5 \times 1{,}127^{x}.$$

La grandeur augmente d'environ 12,7 % par unité de x.

MÉTHODE — Discuter une corrélation

Trois questions à se poser systématiquement.

Étape 1 — Le lien est-il plausible physiquement ?

Étape 2 — Existe-t-il une variable cachée ?
Souvent le temps, la population, la richesse, la saison.

Étape 3 — Le sens de la causalité est-il évident ?

Formulation prudente attendue. « Les deux séries sont fortement corrélées ($r \approx 0{,}96$), mais cela ne prouve pas que x cause y : les deux pourraient dépendre d'un même facteur. »

ERREURS À NE PAS FAIRE

- r proche de 0 ne veut pas dire « pas de lien », mais « pas de lien affine ».
- Extrapoler loin des données sans le signaler.
- Arrondir les coefficients trop tôt : cela fausse les prévisions.
- Confondre la droite de y en x et celle de x en y : ce ne sont pas les mêmes.
- Après linéarisation, oublier de revenir au modèle en y.
- Conclure à une causalité à partir d'un r élevé.

3. Exercices

3.1. Niveau 1 — application directe

Exercice 1 — Point moyen NIVEAU 1 : APPLICATION DIRECTE

On donne la série :

x_i	2	4	6	8	10
y_i	5	8	12	13	17

a) Calcule $\bar{x}$ et $\bar{y}$.

b) Donne les coordonnées du point moyen G.

Exercice 2 — Lecture d'un coefficient

NIVEAU 1 : APPLICATION DIRECTE

Pour chaque valeur de r, dis si un ajustement affine est pertinent.

a) $r = 0{,}993$

b) $r = -0{,}981$

c) $r = 0{,}42$

d) $r = -0{,}07$

Exercice 3 — Prévision

NIVEAU 1 : APPLICATION DIRECTE

La droite d'ajustement d'une série est $y = 3{,}4x + 12{,}6$, obtenue pour $x \in [1\,;10]$.

a) Calcule y pour $x = 6$. S'agit-il d'une interpolation ?

b) Calcule y pour $x = 25$. Que faut-il préciser ?

c) Interprète le coefficient 3,4.

Exercice 4 — Changement de variable

NIVEAU 1 : APPLICATION DIRECTE

On pose $z = \ln y$ et on obtient $z = 0{,}25x + 2$.

a) Exprime y en fonction de x.

b) Calcule e^2 et $e^{0{,}25}$, arrondis à 10^{-3}.

c) De quel pourcentage y augmente-t-elle quand x augmente de 1 ?

3.2. Niveau 2 — entraînement

Exercice 5 — Consommation et vitesse

NIVEAU 2 : ENTRAÎNEMENT

On mesure la consommation d'un véhicule (en L pour 100 km) selon sa vitesse (en km/h).

Vitesse x_i	70	80	90	100	110	130
Conso. y_i	5,2	5,6	6,1	6,9	7,6	9,3

1. Calcule les coordonnées du point moyen.

2. À la calculatrice, donne l'équation de la droite d'ajustement, coefficients arrondis à 10^{-3}.

3. Donne le coefficient de corrélation. L'ajustement est-il pertinent ?

4. Estime la consommation à 120 km/h.

5. Estime la consommation à 30 km/h. Le résultat est-il crédible ? Justifie.

Exercice 6 — Croissance d'une entreprise

NIVEAU 2 : ENTRAÎNEMENT

Le chiffre d'affaires d'une start-up, en milliers d'euros :

Année x_i	0	1	2	3	4
CA y_i	120	186	290	448	700

1. Représente mentalement le nuage. Un ajustement affine te semble-t-il adapté ?

2. Calcule $z_i = \ln y_i$, arrondis à 10^{-3}.

3. Ajuste z en fonction de x (calculatrice) et donne r.

4. Déduis-en une expression de y en fonction de x.
5. Estime le chiffre d'affaires de l'année 6.

Exercice 7 — Corrélation ou causalité ?

NIVEAU 2 : ENTRAÎNEMENT

Pour chaque situation, propose une explication autre que la causalité directe.

1. Dans les villes, le nombre de librairies est fortement corrélé au nombre de cambriolages.
2. Les élèves qui prennent un petit-déjeuner ont de meilleures notes.
3. La taille du pied d'un enfant est corrélée à sa capacité en lecture.
4. Les pays où l'on consomme le plus de chocolat comptent le plus de prix Nobel par habitant.

Exercice 8 — Refroidissement

NIVEAU 2 : ENTRAÎNEMENT

On mesure la température d'un liquide, en °C, au-dessus de la température ambiante de 20 °C.

t_i (min)	0	5	10	15	20
Écart y_i	60	42	29	21	14

1. Calcule $z_i = \ln y_i$, arrondis à 10^{-3}.
2. Ajuste z en fonction de t et donne r.
3. Déduis-en y en fonction de t.
4. Estime l'écart après 30 minutes.
5. Déduis-en la température du liquide à cet instant.

3.3. Niveau 3 — approfondissement

Exercice 9 — Deux ajustements concurrents

NIVEAU 3 : APPROFONDISSEMENT

On étudie la population d'une ville, en milliers :

Année	2000	2005	2010	2015	2020	2025
Rang x_i	0	5	10	15	20	25
Pop. y_i	42	47	53	60	67	76

1. Ajuste y en fonction de x par une droite. Donne l'équation et r.
2. Pose $z = \ln y$ et ajuste z en fonction de x. Donne l'équation et r.
3. Déduis-en le modèle exponentiel.
4. Compare les deux coefficients de corrélation. Quel modèle retenir ?
5. Estime la population en 2040 avec chacun des deux modèles.
6. Commente l'écart entre les deux prévisions.

Exercice 10 — Vrai ou faux — justifie

NIVEAU 3 : APPROFONDISSEMENT

a) Si $r = 0{,}99$, alors x est la cause de y.

b) La droite de régression passe par le point moyen.

c) Si $r = 0$, les variables sont indépendantes.

d) Un coefficient de corrélation peut valoir 1,2.

4. Exercice bilan

EXERCICE BILAN DU CHAPITRE — Type bac — le prix de l'immobilier

Une agence relève le prix moyen du mètre carré, en euros, dans une ville, sur douze ans.

Année	2013	2015	2017	2019	2021	2023	2025
Rang x_i	0	2	4	6	8	10	12
Prix y_i	2100	2280	2490	2710	2960	3210	3500

Partie A — ajustement affine

1. Calcule les coordonnées du point moyen G. *(3 points)*

2. À la calculatrice, donne l'équation de la droite d'ajustement de y en x, coefficients arrondis au centième. *(4 points)*

3. Donne le coefficient de corrélation, arrondi à 10^{-4}. L'ajustement est-il pertinent ? *(3 points)*

4. Interprète le coefficient directeur. *(3 points)*

5. Estime le prix du mètre carré en 2030 avec ce modèle. *(3 points)*

Partie B — ajustement exponentiel

6. Calcule $z_i = \ln y_i$ pour chaque année, arrondis à 10^{-4}. *(4 points)*

7. Ajuste z en fonction de x et donne le coefficient de corrélation. *(4 points)*

8. Déduis-en une expression de y sous la forme $y = A \times q^x$, avec A et q arrondis à 10^{-3}. *(4 points)*

9. Quel est le taux d'évolution annuel moyen selon ce modèle ? *(3 points)*

10. Estime le prix en 2030 avec ce modèle. *(3 points)*

Partie C — choix et discussion

11. Compare les deux coefficients de corrélation. Que peut-on en conclure ? *(3 points)*

12. Compare les deux prévisions pour 2030. Laquelle retiendrais-tu ? *(4 points)*

13. Un article de presse affirme : « le nombre d'agences immobilières de la ville est fortement corrélé au prix du mètre carré ; ouvrir des agences fait donc monter les prix ». Que penses-tu de ce raisonnement ? *(4 points)*

14. Quelles limites vois-tu à ces prévisions pour 2040 ? *(3 points)*

5. Corrections

Correction — Exercice 1

a) $\bar{x} = \dfrac{2+4+6+8+10}{5} = \dfrac{30}{5} = 6$.

$\bar{y} = \dfrac{5+8+12+13+17}{5} = \dfrac{55}{5} = 11$.

b) $G(6\,;11)$.

Correction — Exercice 2

a) $|r| = 0{,}993$: **très pertinent**.
b) $|r| = 0{,}981$: **pertinent**, avec une pente négative.
c) $|r| = 0{,}42$: **non pertinent**, les points sont très dispersés.
d) $|r| = 0{,}07$: **aucune relation affine**.

Correction — Exercice 3

a) $y = 3{,}4 \times 6 + 12{,}6 = 33$.

$6 \in [1\,;10]$: c'est une **interpolation**, donc fiable.

b) $y = 3{,}4 \times 25 + 12{,}6 = 97{,}6$.

Il faut préciser qu'il s'agit d'une **extrapolation** : 25 est très en dehors de la plage observée, et rien ne garantit que la tendance se poursuive.

c) Quand x augmente de 1, y augmente en moyenne de $3{,}4$ unités.

Correction — Exercice 4

a) $y = e^{z} = e^{0{,}25x+2} = e^{2} \times e^{0{,}25x}$.

b) $e^{2} \approx 7{,}389$; $e^{0{,}25} \approx 1{,}284$.

c) $y \approx 7{,}389 \times 1{,}284^{\,x}$: y augmente d'environ $28{,}4\,\%$ par unité de x.

Correction — Exercice 5

1. $\bar{x} = \dfrac{580}{6} \approx 96{,}7$; $\bar{y} = \dfrac{40{,}7}{6} \approx 6{,}78$.

2. À la calculatrice :

$$y \approx 0{,}069x + 0{,}086.$$

3. $r \approx 0{,}992$.

$|r|$ est très proche de 1 : l'ajustement affine est **tout à fait pertinent** sur la plage étudiée.

4. $y \approx 0{,}069 \times 120 + 0{,}086 \approx 8{,}4$ litres pour 100 km.

120 est dans la plage $[70\,;130]$: c'est une interpolation, fiable.

5. $y \approx 0{,}069 \times 30 + 0{,}086 \approx 2{,}2$ litres.

Peu crédible. Aucun véhicule thermique ne consomme 2 L aux 100 km.

En réalité, la consommation *remonte* aux très basses vitesses. Le modèle affine n'est valable que sur la plage mesurée (70 à 130 km/h).

Correction — Exercice 6

1. Les écarts entre valeurs successives augmentent fortement (66, 104, 158, 252) : la croissance n'est pas linéaire.

Un ajustement affine est donc **mal adapté**.

En revanche, les *rapports* sont presque constants : 1,55 ; 1,56 ; 1,54 ; 1,56. C'est le signe d'une croissance exponentielle.

2.

x_i	0	1	2	3	4
z_i	4,787	5,226	5,670	6,105	6,551

3. $z \approx 0{,}441x + 4{,}787$ avec $r \approx 0{,}99999$.

Les points $(x_i\,;z_i)$ sont quasiment alignés : la linéarisation fonctionne parfaitement.

4.

$$y = e^{0{,}441x+4{,}787} = e^{4{,}787} \times \left(e^{0{,}441}\right)^x.$$

$$y \approx 120 \times 1{,}554^{\,x}$$

5. $y(6) \approx 120 \times 1{,}554^6 \approx 120 \times 14{,}08 \approx 1690$ milliers d'euros.

Soit environ 1,7 million d'euros — sous réserve que la croissance se maintienne, ce qui est rare aussi longtemps.

Correction — Exercice 7

1. Facteur commun : la taille de la ville. Une grande ville a à la fois plus de librairies et plus de cambriolages. Rapportés au nombre d'habitants, les deux chiffres n'ont plus de lien particulier.

2. Facteur commun : le milieu familial et l'organisation du foyer. Les familles où l'on prend le temps de déjeuner sont souvent celles qui suivent aussi la scolarité de près.

Le petit-déjeuner a probablement un effet réel, mais l'écart observé le surestime largement.

3. Facteur commun : l'âge. Les enfants plus âgés ont de plus grands pieds *et* lisent mieux. À âge égal, la corrélation disparaît.

4. Facteur commun : la richesse du pays. Les pays riches consomment plus de chocolat et financent davantage la recherche.

C'est un exemple célèbre, publié dans une revue médicale en 2012, souvent cité pour illustrer ce piège.

Correction — Exercice 8

1.

t_i	0	5	10	15	20
z_i	4,094	3,738	3,367	3,045	2,639

2. $z \approx -0{,}0721\,t + 4{,}097$ avec $r \approx -0{,}9995$.

3.

$$y = e^{-0{,}0721t+4{,}097} = e^{4{,}097} \times e^{-0{,}0721t}.$$

$$y \approx 60{,}2\,e^{-0{,}0721\,t}$$

4. $y(30) \approx 60{,}2 \times e^{-2{,}163} \approx 60{,}2 \times 0{,}1150 \approx 6{,}9$ degrés d'écart.

5.

$$T = 20 + 6{,}9 = 26{,}9\,^\circ\text{C}.$$

Ce modèle exponentiel est exactement celui que donne l'équation différentielle du refroidissement vue au chapitre 4 : les deux approches se rejoignent.

Correction — Exercice 9

1. À la calculatrice :

$$y \approx 1{,}354x + 40{,}57 \quad \text{avec} \quad r \approx 0{,}9956.$$

2. $z_i = \ln y_i$: 3,738 ; 3,850 ; 3,970 ; 4,094 ; 4,205 ; 4,331.

$$z \approx 0{,}02373x + 3{,}7347 \quad \text{avec} \quad r \approx 0{,}99987.$$

3.

$$y = e^{3{,}7347} \times \left(e^{0{,}02373}\right)^x \approx 41{,}9 \times 1{,}0240^{\,x}.$$

La population croît d'environ 2,4 % par an.

4. 0,99987 > 0,9956 : l'ajustement exponentiel est **légèrement meilleur**.

C'est cohérent avec la nature du phénomène : une population croît par multiplication, pas par addition d'un nombre fixe.

Attention : les deux r sont excellents. Sur une plage courte, un modèle exponentiel et un modèle affine sont difficiles à départager.

5. 2040 correspond à $x = 40$.

Modèle affine : $y \approx 1{,}354 \times 40 + 40{,}57 \approx 95$ milliers.

Modèle exponentiel : $y \approx 41{,}9 \times 1{,}0240^{40} \approx 41{,}9 \times 2{,}582 \approx 108$ milliers.

6. L'écart atteint 13 000 habitants, soit plus de 13 %.

Sur la plage observée, les deux modèles collent presque aussi bien ; c'est en *extrapolant* qu'ils divergent.

Plus on s'éloigne des données, plus le choix du modèle pèse : c'est précisément pour cela qu'il faut annoncer une prévision avec prudence.

Correction — Exercice 10

a) Faux. Un r élevé indique un lien statistique fort, pas une causalité. Il faut une explication du mécanisme.
b) Vrai. C'est une propriété de la droite des moindres carrés.
c) Faux. $r = 0$ signifie « aucune relation *affine* ». Les points peuvent être parfaitement placés sur une parabole.
d) Faux. r appartient toujours à $[-1\,;1]$. Une valeur hors de cet intervalle signale une erreur de calcul.

Correction — Exercice bilan — partie A

1. $\bar{x} = \dfrac{0+2+4+6+8+10+12}{7} = \dfrac{42}{7} = 6.$

$\bar{y} = \dfrac{19\,250}{7} = 2750.$

2. À la calculatrice :

$$y \approx 116{,}61x + 2050{,}36.$$

3. $r \approx 0{,}9974$.

$|r|$ est très proche de 1 : l'ajustement affine est **pertinent** sur la période observée.

4. Le prix du mètre carré augmente en moyenne de **116,61 € par an** sur la période 2013–2025.

5. 2030 correspond à $x = 17$:

$$y \approx 116{,}61 \times 17 + 2050{,}36 \approx 1982{,}4 + 2050{,}4 \approx 4033\,€.$$

Il s'agit d'une extrapolation.

Correction — Exercice bilan — parties B et C

6.

x_i	0	2	4	6
z_i	7,6497	7,7319	7,8200	7,9047

x_i	8	10	12
z_i	7,9929	8,0740	8,1605

7.

$$z \approx 0{,}042671x + 7{,}648810$$

avec $r \approx 0{,}99996$.

8.

$$y = e^{7{,}648810} \times \left(e^{0{,}042671}\right)^x.$$

$$e^{7{,}648810} \approx 2098{,}150 \qquad e^{0{,}042671} \approx 1{,}043595.$$

$$y \approx 2098{,}150 \times 1{,}044^{\,x}$$

9. $q \approx 1{,}0436$: le taux d'évolution annuel moyen est d'environ $+4{,}4\,\%$.

10. $x = 17$:

$$y \approx 2098{,}15 \times 1{,}043595^{17} \approx 2098{,}15 \times 2{,}0656 \approx 4334\,€.$$

11. $0{,}99996 > 0{,}9974$: l'ajustement exponentiel est **meilleur**, même si les deux sont excellents.

C'est logique : les prix évoluent en pourcentage, pas par ajout d'une somme fixe.

12. Affine : 4033 €. Exponentiel : 4334 €. Écart : 301 €, soit environ 7,5 %.

Je retiendrais le **modèle exponentiel** : il colle mieux aux données, et il correspond à la façon dont les prix évoluent réellement (en pourcentage).

Il faut cependant présenter les deux valeurs comme un *ordre de grandeur*, entre 4000 € et 4350 €.

13. Le raisonnement est **fautif** : il confond corrélation et causalité.

L'explication la plus probable est une *causalité inversée* : c'est parce que les prix montent, et que le marché est actif, que des agences ouvrent.

On peut aussi invoquer un facteur commun : l'attractivité de la ville fait monter les prix *et* attire les agences.

Test simple : fermer des agences ne ferait évidemment pas baisser les prix.

14. Trois limites principales :

• 2040 correspond à $x = 27$, soit plus du double de la plage observée : l'extrapolation est très lointaine ;

• un modèle exponentiel prédit une croissance illimitée, ce qui est impossible — les prix sont bornés par les revenus des acheteurs ;

• le marché immobilier dépend de facteurs imprévisibles (taux d'intérêt, crises, politiques du logement) qu'aucun ajustement statistique ne peut anticiper.