Questions de cours — Statistique à deux variables (réponses)

Nuage de points, point moyen, droite des moindres carrés, coefficient de corrélation, prévisions, changement de variable, corrélation et causalité

Version réponses : le cours complet, rangé question par question · 8 questions

Terminale — Mathématiques complémentaires

CE QUE TU DOIS SAVOIR FAIRE À LA FIN DE CETTE FICHE

- ☐ Le nuage de points et le point moyen.
- ☐ La droite des moindres carrés (calculatrice), l'interprétation de son coefficient directeur et du coefficient de corrélation r.
- ☐ Faire une prévision : interpolation, extrapolation.
- ☐ Linéariser un modèle exponentiel avec $z = \ln y$, puis revenir au modèle.
- ☐ Distinguer corrélation et causalité ; savoir **quel outil choisir**.

CONSIGNES

— **Version réponses** : c'est le cours complet du chapitre, rangé question par question.

— Compare avec ta fiche : **apprends seulement les questions que tu ne savais pas**, puis refais-les sans regarder.

— Pour chaque question : d'abord la **réponse de cours** (définition, théorème avec ses hypothèses, méthode en étapes), puis l'**application**, rédigée comme au bac.

Partie	Thème	Questions	Durée
A	Nuage, point moyen, droite d'ajustement	1 – 2	20 min
B	Corrélation et prévisions	3 – 4	15 min
C	Ajustement par changement de variable	5 – 6	20 min
D	Corrélation et causalité	7	10 min
E	Organiser son cours : quel outil choisir ?	8	10 min

Environ 1 h 15, en une fois. Calculatrice autorisée (menus statistiques et régression).

PARTIE A — Nuage, point moyen, droite d'ajustement — 20 min

On étudie deux caractères mesurés sur les mêmes individus.

Q1 — Nuage de points et point moyen

Qu'est-ce que le nuage de points d'une série statistique à deux variables ? Définis son point moyen.

Réponse

C'est l'ensemble des points $M_i(x_i\,;y_i)$ dans un repère. Le point moyen est $G(\bar{x}\,;\bar{y})$, avec $\bar{x} = \dfrac{x_1+\cdots+x_n}{n}$ et $\bar{y} = \dfrac{y_1+\cdots+y_n}{n}$.

Application. Série : x_i : 1, 2, 3, 4, 5 et y_i : 3, 5, 6, 9, 12. Calcule les coordonnées du point moyen.

Solution

$\bar{x} = \dfrac{15}{5} = 3$ et $\bar{y} = \dfrac{35}{5} = 7$: $G(3\,;7)$.

Q2 — La droite des moindres carrés

Qu'est-ce que la droite d'ajustement par la méthode des moindres carrés ? Par quel point passe-t-elle ? Comment interprète-t-on son coefficient directeur ?

Réponse

C'est la droite $y = ax + b$ qui rend **minimale la somme des carrés des écarts verticaux** entre les points du nuage et la droite. On l'obtient à la calculatrice (régression linéaire). Elle passe toujours par le point moyen G. Le coefficient a : quand x augmente de 1, y augmente en moyenne de a.

Application. Pour la série de la question 1, la calculatrice donne $y = 2{,}2x + 0{,}4$. Vérifie qu'elle passe par G et interprète 2,2.

Solution

$2{,}2 \times 3 + 0{,}4 = 7 = \bar{y}$: elle passe par G. Quand x augmente de 1, y augmente en moyenne de 2,2.

PARTIE B — Corrélation et prévisions — 15 min

L'ajustement est-il bon ? Peut-on s'en servir pour prévoir ?

Q3 — Le coefficient de corrélation

Que mesure le coefficient de corrélation linéaire r ? Entre quelles valeurs est-il compris ? Comment l'interprète-t-on ?

Réponse

Il mesure la qualité de l'ajustement **affine**. $-1 \leqslant r \leqslant 1$, et r a le signe de a. Si $|r|$ est proche de 1 (par exemple $|r| > 0{,}95$), l'ajustement affine est très bon ; si r est proche de 0, il n'y a pas de relation affine (mais il peut y avoir une autre relation).

Application. Pour la série de la question 1, la calculatrice donne $r \approx 0{,}98$. Conclus.

Solution

r est proche de 1 : l'ajustement affine est très satisfaisant, et y augmente avec x.

Q4 — Interpolation et extrapolation

Qu'est-ce qu'une interpolation ? une extrapolation ? Laquelle est la plus fiable ?

Réponse

Interpolation : prévision **à l'intérieur** de la plage des données ; extrapolation : prévision **au-delà**.

L'extrapolation suppose que la tendance continue : elle est moins fiable, il faut le dire dans la conclusion.

Application. Avec $y = 2{,}2x + 0{,}4$, estime y pour $x = 3{,}5$ puis pour $x = 20$. Commente.

Solution

$x = 3{,}5$: $y = 8{,}1$ (interpolation, fiable). $x = 20$: $y = 44{,}4$ (extrapolation loin des données : à prendre avec prudence).

PARTIE C — Ajustement par changement de variable — 20 min

Quand le nuage n'est pas aligné, on le transforme.

Q5 — Linéariser un modèle exponentiel

Pour un nuage de forme exponentielle, quel changement de variable fait-on ? Comment revient-on au modèle $y = A\,\mathrm{e}^{bx}$?

Réponse

On pose $z = \ln y$ ($y > 0$) : si $y = A\,\mathrm{e}^{bx}$, alors $z = bx + \ln A$, qui est affine en x. On ajuste z par une droite $z = \alpha x + \beta$ (calculatrice, avec les $z_i = \ln y_i$), puis $y = \mathrm{e}^z = \mathrm{e}^{\beta}\,\mathrm{e}^{\alpha x}$: $A = \mathrm{e}^{\beta}$ et $b = \alpha$.

Application. L'ajustement de $z = \ln y$ en x donne $z = 0{,}3x + 1{,}2$. Écris y en fonction de x et estime y pour $x = 5$.

Solution

$y = \mathrm{e}^{1{,}2}\,\mathrm{e}^{0{,}3x} \approx 3{,}32\,\mathrm{e}^{0{,}3x}$. Pour $x = 5$: $z = 2{,}7$ et $y = \mathrm{e}^{2{,}7} \approx 14{,}9$.

Q6 — Choisir un modèle

Comment choisit-on entre un ajustement affine et un ajustement exponentiel ?

Réponse

On regarde l'**allure du nuage** (alignée, ou qui s'incurve de plus en plus vite) et on compare les coefficients de corrélation : r pour $(x\,;y)$ et r pour $(x\,;\ln y)$. On garde le modèle dont $|r|$ est le plus proche de 1, s'il est cohérent avec la situation.

Application. Un nuage s'incurve vers le haut ; $r = 0{,}91$ pour $(x\,;y)$ et $r = 0{,}998$ pour $(x\,;\ln y)$. Quel modèle choisir ?

Solution

Le modèle exponentiel : les points $(x\,;\ln y)$ sont presque parfaitement alignés.

PARTIE D — Corrélation et causalité — 10 min

Deux grandeurs liées ne sont pas forcément cause l'une de l'autre.

Q7 — Corrélation n'est pas causalité

Une forte corrélation entre deux variables prouve-t-elle que l'une est la cause de l'autre ? Donne les explications possibles d'une corrélation.

Réponse

Non. Une corrélation peut venir d'une causalité réelle, d'un **facteur commun** (une troisième variable agit sur les deux), d'une causalité **inversée**, ou d'une simple **coïncidence**. Une corrélation signale une relation à expliquer, elle ne la démontre pas.

Application. Dans les villes françaises, le nombre de pharmacies est fortement corrélé au nombre de naissances. Les pharmacies font-elles naître des enfants ?

Solution
Non : c'est un facteur commun, la **taille de la population** de la ville, qui fait augmenter les deux.

PARTIE E — Organiser son cours : quel outil choisir ? 10 min

Complète ce tableau : il résume tout le chapitre.

Q8 — Pour chaque question de statistique

Pour chaque situation, quel outil utilises-tu ?

On me demande . . .	**J'utilise . . .**
Le point moyen	$G(\bar{x}\,;\bar{y})$.
Une équation de la droite d'ajustement	La calculatrice (régression linéaire) ; arrondis demandés.
« L'ajustement est-il justifié ? »	L'allure du nuage et r proche de ± 1.
Une estimation	Remplacer x dans l'équation ; dire si c'est une extrapolation.
Un nuage qui s'incurve	$z = \ln y$, ajustement de z, puis $y = \mathrm{e}^z$.
« Peut-on dire que x cause y ? »	Non sans autre argument : chercher un facteur commun.